



02

FUNDAMENTOS DE LA IA

UNIDAD 2: FUNDAMENTOS DE LA IA

Les damos la bienvenida a Generación IA el primer curso de alfabetización digital sobre IA Generativa en Latinoamérica.

Generación IA es una formación desarrollada por Eidos Global y Microsoft que tiene como objetivo ampliar el horizonte de oportunidades laborales de las personas en Latinoamérica y Caribe ante la nueva economía mundial transformada por la inteligencia artificial.

Es una experiencia consolidada, un espacio seguro para aprender a hacer uso del potencial de esta tecnología que está transformando nuestras formas de trabajar. Generación IA es un espacio para aprender a utilizar esta tecnología de forma responsable y creativa. A través de módulos interactivos y recursos actualizados, explorarán los fundamentos de la IA y descubrirás cómo puede optimizar procesos, mejorar la toma de decisiones y beneficiar a la comunidad

¿Qué vamos a ver en esta unidad?

En esta unidad exploraremos los pilares fundamentales que han impulsado el auge de la Inteligencia Artificial, especialmente en el ámbito generativo. Sin adentrarnos en tecnicismos excesivos, descubriremos los conceptos clave que permiten a la IA crear contenido original y realista. Nuestro objetivo es que comprendas los mecanismos básicos que operan detrás de escena de esta tecnología transformadora.

Abordaremos temas esenciales como el origen de los datos en el contexto del Big Data, la diferencia entre datos estructurados y no estructurados, y cómo el Machine Learning y el Deep Learning, a través de redes neuronales artificiales, hacen posible el entrenamiento de modelos. Además, desmitificaremos algunas creencias erróneas, como la idea de que la IA genera resultados completamente objetivos.

¿De dónde vienen los datos?

Como mencionamos anteriormente, **uno de los pilares fundamentales para la aparición de la IA tal cual la conocemos actualmente fue la cantidad enorme de datos que circulan de manera digital**. Pero entonces, ¿de dónde vienen los datos que acumulan? Según un informe de la agencia DOMO, cada minuto se suben más de 500 horas de video en

YouTube, se comparten 150.000 mensajes en Facebook y se postean 347.222 historias en Instagram. Cada 60 segundos se registran 319 usuarios nuevos en X (Ex Twitter) y se realizan casi 70.000 solicitudes de puestos de trabajo en LinkedIn. Es importante entender que los datos que se generan diariamente provienen de fuentes muy variadas. Podemos pensarlo en términos de fuentes de organismos públicos y privados.

Los organismos del sector público ocupan una posición interesante en lo que respecta a la generación de datos. Muchas operaciones gubernamentales se relacionan con el mantenimiento de los registros civiles (por ejemplo, nacimientos, matrimonios). Los gobiernos también conservan una gran cantidad de datos de otro tipo, incluyendo datos geoespaciales y meteorológicos procedentes de satélites, registros de bienes y registros de salud y seguridad, entre muchos otros.

En el sector privado, las empresas recopilan datos sobre sus clientes, empleados y proveedores con el fin de administrar sus negocios de manera más eficiente. Los usuarios de los servicios basados en la web también generan diversos tipos de datos. Por ejemplo, el uso de teléfonos móviles y computadoras, la navegación por la Web, el uso de redes sociales y el realizar compras generan una cantidad importante de datos, **contribuyendo así al fenómeno del Big Data**. Con la llegada de nuevas tecnologías se dispone de importantes fuentes adicionales de datos, incluyendo el acceso a los datos generados por todo tipo de dispositivos electrónicos, sensores, aparatos, máquinas y vehículos.

Big Data

Cuando hablamos de datos, hablamos de un fenómeno que se viene generando desde hace un tiempo. Un factor clave que contribuye al auge de las aplicaciones de IA es el hecho de que muchas interacciones diarias son ahora digitales o asistidas digitalmente y generan un volumen importante de datos. Se estima que el 90% de los datos del mundo se crearon sólo en los últimos años y que las tasas de generación de datos siguen acelerándose (Marr, 2018).

Las personas generan millones de datos en tan solo un minuto de Internet. Y, a su vez, diversos sistemas interconectados registran rutas de vuelos, transacciones financieras, multas de tránsito, calificaciones de estudiantes y más. Estamos rodeados de un gran volumen de datos, y a esto se lo denomina macrodatos o Big Data. En otras palabras, **se entiende por Big Data a la inmensa cantidad de datos almacenados, algunos más grandes**

y complejos que otros como videos, imágenes, audios, etc., que, a la vez, pueden ser procesados y accesibles de formas muy eficaces.

El objetivo final es extraer valor de los datos. Esto puede implicar identificar patrones, hacer predicciones, y tomar decisiones basadas en el análisis de grandes conjuntos de datos. Para algunas personas especialistas se entiende al Big Data no solo al volumen de datos acumulados sino también a la **relación que se establece entre todos esos datos.**

Este fenómeno se caracteriza por 4 principios (o las 4 V): **velocidad, volumen, variedad y veracidad.**

Volumen

Cuando hablamos sobre Big Data hablamos de algo GRANDE. Algo que es tan grande que es imposible de imaginar. En la actualidad describimos el tráfico en internet en términos de petabytes y exabytes (1 exabyte equivale a 36 mil años de video en HDTV, o transmitir el catálogo completo de Netflix 3 mil veces). En 2012, 2.5 exabytes de datos fueron creados cada mes. ¡Hoy, tomaría hasta cinco años ver la cantidad de video que cruza las redes globales cada segundo! Eso es más tráfico en un segundo que lo había almacenado en todo internet hace 20 años. Dentro de este universo de datos se encuentran almacenados información y relaciones valiosas.

¿Qué podemos hacer con todos estos datos? No solo analizar las transacciones en línea de los clientes, también qué productos han buscado, sus rutas de navegación a través del sitio web de la empresa, cómo los anuncios, reseñas y diseño de página influenciaron su comportamiento, sus datos sociales y geográficos, así como su historial de compras. Luego utilizar esos datos para una ventaja competitiva inmediata al presentar promociones relevantes y recomendar compras adicionales.

Veracidad

La veracidad se refiere a la **calidad, precisión y confiabilidad de los datos recolectados.** Como tal, la veracidad no es necesariamente una característica distintiva del Big Data (ya que incluso los datos pequeños deben ser confiables), pero debido al alto volumen, variedad y velocidad, una alta fiabilidad es de suma importancia si se quieren obtener conclusiones precisas. Los datos de alta veracidad son realmente valiosos y contribuyen de manera significativa a los resultados generales. Y deben ser de alta calidad. Por ejemplo, si estamos analizando datos de X o Twitter, es imperativo que los datos se extraigan directamente de este sitio, en lugar de provenir de algún sistema de terceros que podría no ser confiable. Se estima que los datos de baja veracidad o malos datos cuestan a las empresas

estadounidenses más de \$3.1 billones al año debido a que se toman malas decisiones basadas en ellos, así como al dinero gastado en limpiar, depurar y rehabilitar esos datos.

Variedad

¿Cuál es la parte de datos en Big Data? La mayoría de los datos de hoy no vienen en paquetes bien organizados. No caben en las tablas estáticas de las bases de datos estructuradas y tradicionales. De hecho, más del 80% de los datos actuales no están estructurados: mensajes, actualizaciones e imágenes publicadas en redes sociales; lecturas de sensores; y señales GPS. Teléfonos móviles, compras en línea, redes sociales, sensores de datos – todos producen un tsunami diario de datos no estructurados, los cuales cuentan con información que podría impactar a su negocio. **De hecho, el 80% de los datos viene de videos e imágenes.**

Velocidad

La velocidad de los datos significa que **los datos fluyen a un ritmo cada vez más acelerado**. Y entre más rápido los puedan procesar y analizar, más rápido se puede obtener información. En la era de internet y lo móvil, más gente entrega y consume productos y servicios de manera digital, lo que genera retroalimentación instantánea de datos a diversas organizaciones. La era del smartphone ha levantado la tasa del flujo de datos, pues cientos de millones de consumidores caminan, hablan con productores de información, y llevan con ellos una fuente de transmisión de datos de ubicación y audio en vivo.

El volumen de información aumenta a cada minuto, y cada vez más sistemas registran un dato tras otro. El Big Data es considerado como el oro del siglo XXI, ya que con su procesamiento y análisis las organizaciones pueden tomar mejores decisiones. Sin embargo, los macrodatos también abren nuevos interrogantes sobre la ética, la privacidad y los derechos de las personas en esta sociedad conectada.

Fuentes: [¿Qué es eso llamado Big Data? - News Center Latinoamérica \(microsoft.com\)](http://newscenter.microsoft.com)

[Big data: cómo entender el mundo en el que los datos crecen a cada segundo \(fundacionbyb.org\)](http://fundacionbyb.org)

Datos estructurados y no estructurados

Cuando hablamos de **Big Data**, hablamos de un caudal inmenso de datos, en general desorganizados, sin una estructura identificada, como por ejemplo, mensajes en servicios de mensajería instantánea, correos electrónicos, compras en tiendas online, o archivos (video, imágenes, audio, etc). Es muy importante comprender en este punto que un dato, por sí solo, no tiene valor y no significa nada. **Un dato tiene utilidad recién cuando se lo relaciona con otros datos.** Allí, en esta relación, es donde se genera información, y dependiendo de cómo sea esa relación, la información obtenida será más o menos útil y confiable.

Los **datos no estructurados** son datos que no están organizados de una manera predefinida o carecen de una estructura de datos específica.

Mientras tanto, los **datos estructurados** son datos que tienen relaciones claras, o sea una estructura que los contiene.

Los **datos estructurados** a menudo se guardan en tablas como archivos de Excel. En estos casos, las filas y columnas de los datos contienen diferentes variables o características y, a menudo, es posible discernir la relación entre los puntos de datos comprobando dónde se cruzan las filas y las columnas de datos.

Los **datos no estructurados** son datos que no están organizados de acuerdo con un modelo o estructura de datos predefinidos. Los datos no estructurados a menudo se denominan datos cualitativos porque no se pueden analizar ni procesar de manera tradicional utilizando los métodos habituales que se utilizan para los datos estructurados. Los datos no estructurados son difíciles de analizar, y dar sentido a los datos no estructurados a menudo implica examinar datos individuales para discernir características potenciales y luego observar si esas características ocurren en otros datos dentro del grupo. En términos de aprendizaje automático, ciertas técnicas pueden ayudar a ordenar datos no estructurados y convertirlos en datos estructurados. Una herramienta popular para convertir datos no estructurados en datos estructurados es un sistema llamado codificador automático.

La combinación de ambos tipos de datos permite una comprensión más completa y rica. Por ejemplo, en el análisis de clientes, los datos estructurados sobre transacciones pueden combinarse con datos no estructurados de comentarios en redes sociales para obtener una visión más detallada del comportamiento y preferencias de clientes.

Podríamos decir entonces que los datos estructurados facilitan el análisis cuantitativo y la toma de decisiones basadas en reglas, mientras que los datos no estructurados permiten a la IA comprender y generar lenguaje, imágenes y otros contenidos complejos. Juntos, enriquecen la capacidad de los sistemas de IA para ofrecer soluciones más precisas y completas.

Machine Learning (aprendizaje automático)

El Machine Learning o aprendizaje automático es una de las tantas tecnologías fundamentales que permite que la IA exista como la conocemos hoy. Específicamente, es lo que le brinda la capacidad de aprender de forma autónoma a la inteligencia artificial y predecir escenarios posibles. **En el Machine Learning, el sistema de IA aprende a partir del procesamiento de datos y algoritmos de aprendizaje, en lugar de hacerlo mediante la programación manual o clásica hecha por una persona.** Esto es lo que la diferencia principalmente de otras tecnologías. Además, brinda la capacidad autónoma de aprender las relaciones entre diversas variables. Anteriormente, el ser humano debía entrenar muchísimo a una IA, indicando y brindando un conjunto de datos para poder establecer cuáles son las relaciones entre las variables.

Programación Clásica

La programación clásica requiere plenamente de la intervención humana. Lo que los humanos aportan son las reglas (algoritmos) y los datos, para así poder obtener como resultado respuestas esperadas.

Por ejemplo, si uno creara una calculadora programaría las operaciones que se deben hacer y los tipos de datos que se pueden recibir. En este caso, las reglas serían las operaciones matemáticas como sumar, restar, multiplicar, dividir, etc, y los datos serían los números.

El gran problema de la programación clásica es que no permite generar nuevas reglas y, por ende, son estructuras rígidas y muy costosas de flexibilizar o adaptar ante nuevos escenarios. En un mundo tan cambiante esto empezó a ser un problema.

Después de preparar los datos de entrenamiento, el modelo de IA se entrena de forma iterativa. Durante este proceso se pueden probar diferentes algoritmos y conjuntos de datos de aprendizaje automático, y se selecciona y ajusta el modelo óptimo para un rendimiento predictivo preciso.

Machine Learning

Ante un mundo donde las evoluciones tecnológicas y cambios son cada vóz más rápidos e imprevisibles, la programación tuvo que comenzar a diseñar cómo lograr que los sistemas puedan "aprender" y adaptarse para poder dar respuestas precisas en diversos escenarios más o menos controlados.

Así nace el Machine Learning, que a diferencia de la Programación Clásica, lo que los humanos realizan manualmente es ofrecer los datos de entrada y el resultado de salida esperado. De esta forma, lo que dejan de lado los humanos es el diseño de las reglas, delegando esta tarea a la propia computadora, para que diseñe y optimice sus propias reglas, mientras que como humanos solamente se pone el foco en la entrada y salida del sistema. Esto garantiza hoy en día una nueva forma de programar sistemas, muy distinta a lo que sucedía años anteriores.

Después de preparar los datos de entrenamiento, **el modelo de IA se entrena de forma iterativa**. Durante este proceso se pueden probar diferentes algoritmos y conjuntos de datos de aprendizaje automático, y se selecciona y ajusta el modelo óptimo para un rendimiento predictivo preciso.

Esta técnica se basa en el reconocimiento de patrones siguiendo tres pasos:

1. Datos. Recopilación de datos
2. Entrenamiento. Entrenamiento del modelo
3. Predicciones. Utilizar el modelo para hacer predicciones

¿Cómo se aplican estos conceptos en la vida diaria?

Datos. Recopilación de datos

La recopilación de datos es crucial porque el modelo de machine learning necesita ejemplos para aprender. Sin datos, no hay información que el modelo pueda utilizar para aprender patrones.

Ejemplo: Imagina que queremos construir un modelo para identificar imágenes de perros y gatos. Primero, necesitamos recopilar muchas imágenes de ambos animales. Estas imágenes son nuestros datos. Aseguramos que tenemos una variedad de imágenes con diferentes razas, ángulos, tamaños y condiciones de iluminación. Luego esta imagen la convertimos en un vector de números que sea entendible por el algoritmo.

Entrenamiento. Entrenamiento del modelo

Entrenar un modelo significa enseñarle a reconocer patrones en los datos. Utilizamos algoritmos que ajustan el modelo para que pueda diferenciar entre diferentes categorías (por ejemplo, perros y gatos).

Ejemplo: Usamos las imágenes recopiladas y las etiquetamos como "perro" o "gato". Alimentamos estas imágenes etiquetadas al algoritmo de machine learning. El algoritmo ajusta el modelo basándose en las características de las imágenes (como colores, formas y texturas) que diferencian a los perros de los gatos.

Predicciones. Utilizar el modelo para hacer predicciones

Un modelo entrenado puede analizar datos nuevos y hacer predicciones basadas en lo que ha aprendido. Una de las métricas más utilizadas es la precisión del modelo, es decir, el porcentaje de predicciones que el modelo realiza correctamente. Siempre se intenta generar un modelo que aumente el % de precisión y disminuya el error pero teniendo en cuenta que hay que evitar sobreentrenar al modelo.

Ejemplo: Es decir si el modelo tiene 100 imágenes y acierta en 90 el modelo tiene una precisión del 90% . Podemos mostrarle una nueva imagen de un animal y preguntarle si es un perro o un gato. El modelo analiza la nueva imagen y hace una predicción basada en los patrones que aprendió durante el entrenamiento.

Conclusión Final.

Hoy en día, el Machine Learning, ha logrado reducir significativamente este esfuerzo y abierto a la posibilidad de crear modelos predictivos cada vez más actualizados y con mayor cantidad de relaciones establecidas. La otra cara de la moneda, es que tienen la desventaja de que dichos aprendizajes autónomos y no supervisados no siempre son del todo correctos y es allí donde el ser humano debe hacer un uso cauteloso y responsable de dichas tecnologías que utilicen Machine Learning.

Deep Learning (Aprendizaje profundo)

Introducción

Deep learning es una rama del machine learning que utiliza redes neuronales artificiales con muchas capas (por eso se llama "profundo") para aprender y reconocer patrones complejos a partir de grandes cantidades de datos. Estas redes son especialmente buenas para tareas como el reconocimiento de imágenes, el procesamiento del lenguaje natural y la conducción autónoma.

Este modelo, para comprenderlo con fines didácticos, se compone como el cerebro, o sea de neuronas y conexiones. Aquí, a las neuronas se las conocen como celdas, y son las unidades donde se procesan las señales recibidas, o sea los datos, que luego son enviados a otras celdas para que sigan siendo procesados. Este sistema es muy complejo de entender, pero lo importante a conocer es que es al recibir un dato, la red neuronal se encarga de descomponerlo en pequeñas partes, y a través de diferentes decisiones y conexiones, comienza a procesar los datos en paralelo hasta llegar a arrojar un resultado final.

Veamos un ejemplo concreto de cómo funciona el deep learning:

1. Recopilación de Datos: Para entrenar un modelo de deep learning para distinguir entre imágenes de perros y gatos. Primero, necesitamos un gran conjunto de datos de imágenes de perros y gatos. Supongamos que tenemos 10,000 imágenes etiquetadas: 5,000 de perros y 5,000 de gatos.

- **Cada imagen** está etiquetada como "perro" o "gato".
- **Variabilidad:** Las imágenes tienen diferentes razas, tamaños, colores, posiciones y entornos (interiores, exteriores).

2. El Entrenamiento del Modelo divide la información en distintas capas neuronales que es ideal para tareas de visión por computadora, como el reconocimiento de imágenes.

Estas capas detectan características básicas en las imágenes, como bordes, texturas y patrones. Por ejemplo, una capa podría detectar las orejas puntiagudas de un perro o las orejas redondas de un gato. Estas capas reducen la complejidad de los datos, simplificando la información relevante mientras mantienen las características importantes. Aquí, la red combina todas las características detectadas para hacer una clasificación final, determinando si la imagen es de un perro o un gato.

3. Predicciones: Una vez que el modelo ha sido entrenado, podemos darle una nueva imagen (que no ha visto antes) y pedirle que prediga si es un perro o un gato.

Entrada: Una nueva imagen, por ejemplo, una foto de un gato.

Salida: El modelo analiza la imagen, pasa por todas las capas de la red, y finalmente predice: "Esta imagen es un gato" con una cierta probabilidad (por ejemplo, 95% gato, 5% perro)

Conclusión final

En conclusión el deep learning utiliza redes neuronales profundas para analizar imágenes y aprender a reconocer patrones. Gracias a los nuevos modelos matemáticos denominados Deep Learning y los avances tecnológicos en materia de diseño de algoritmos, base de datos y procesamiento de los mismos, se ha logrado potenciar aún más el Machine Learning, pudiendo así generar modelos matemáticos que se ajusten de forma autónoma de forma mucho más eficiente. Es así, que la aparición de los modelos matemáticos Deep Learning, dieron un nuevo potencial al Machine Learning en cuanto a su capacidad para aprender y potenciaron el surgimiento de nuevos modelos de IA en el mercado.

Redes neuronales artificiales (RNA)

Introducción

La etimología de la red neuronal viene inspirada por las redes neuronales biológicas que forman parte del cerebro humano. En este sentido, el paralelismo es directo entre las neuronas de una red neuronal artificial y las de una red biológica. Una red neuronal se basa en la interacción de muchas partes simples trabajando conjuntamente para obtener un resultado que puede ser más o menos abstracto según la complejidad de la red. Es a cada una de esas partes simples a lo que llamamos neurona. Es decir, una neurona es la unidad básica de información de una red neuronal. Los científicos estiman que el cerebro humano tiene hasta 100 mil millones de neuronas. En concreto, son células nerviosas conectadas entre sí mediante sinapsis, las cuales transmiten información enviando impulsos eléctricos de manera bidireccional, durante el proceso de “excitación” o “activación” de las neuronas.

Las Redes Neuronales Artificiales (RNA) tratan de imitar estos mecanismos y comportamientos utilizando las matemáticas. Los algoritmos de las RNA están diseñados para tener tres componentes principales: una capa de entrada (Input), una capa oculta (Hidden) y una capa de salida (Output). Cada capa está compuesta por varias neuronas o nodos. Cada nodo contiene información en forma de un número. Todos los nodos de la capa de entrada están enlazados con nodos de la capa oculta que a su vez están enlazados con nodos de la capa de salida. Estas conexiones son posibles gracias al uso de varias funciones matemáticas. La transmisión de información de una capa a la siguiente se lleva a cabo mediante otras funciones matemáticas denominadas funciones de activación.

Veamos un ejemplo, en el caso de una RNA utilizada para clasificar imágenes, los nodos de la capa de entrada reciben el valor del color de cada pixel de la imagen; se espera que la capa de salida especifique si la imagen representa un perro o un gato o algo diferente según la aplicación. Durante la fase de entrenamiento, se presentan a la RNA imágenes que ya fueron identificadas como un perro o un gato. Con cada nueva imagen de entrenamiento, la RNA aprende a modificar los coeficientes de sus funciones de activación para producir la respuesta gato/perro esperada.

Entrenamiento y tipos de aprendizaje

El entrenamiento es el corazón de un modelo de Machine Learning. Durante este proceso, el modelo aprende de una vasta cantidad de datos, identificando patrones ocultos. Combinar diferentes tipos de datos y técnicas de aprendizaje es fundamental para lograr un modelo versátil y capaz de realizar predicciones precisas en una amplia gama de escenarios.

Tipos de entrenamiento

El entrenamiento de modelos de Machine Learning se basa en diferentes paradigmas de aprendizaje. El aprendizaje supervisado utiliza datos etiquetados para mapear entradas a salidas deseadas. El aprendizaje por refuerzo se centra en la interacción con un entorno para maximizar una recompensa acumulada. Y el aprendizaje no supervisado busca descubrir estructuras ocultas en datos no etiquetados.

Aprendizaje supervisado

Una forma de entrenamiento, o sea de enseñarle algo a un sistema de Machine Learning, es brindando un **conjunto de datos ya etiquetado**. Este tipo de entrenamiento se conoce como aprendizaje supervisado. En simples palabras, sería como brindar una planilla de Excel, donde ya hay elementos analizados y bajados a datos por humanos.

Por ejemplo, si tomamos el ejemplo de una IA que está diseñada para adivinar el idioma en que habla una persona a partir de un audio de voz, es necesario primero que una persona le brinde una tabla de datos, donde indica que tal sonido, representa tal palabra y que esa palabra pertenece al idioma, por ejemplo "Español". A partir de estos ejemplos concretos, o sea datos etiquetados, es que luego el sistema de Machine Learning comenzará a generar sus propias relaciones, descomponiendo los audios de voz y relacionándolos con los datos supervisados y brindados. El aprendizaje supervisado es como una base de conocimiento desde la cuál el Machine Learning puede comenzar a aprender frente a nuevos estímulos.

Aprendizaje por refuerzo

Otra forma de entrenamiento posible es el **aprendizaje por refuerzo**. Hay situaciones, que son tan complejas de descomponer y describir que es imposible entrenar a

un sistema de Machine Learning con datos de ejemplo. Es en estas situaciones, el entrenamiento se basa puntualmente en poder indicarle, a modo de recompensa y reforzamiento, cuando dicho sistema está haciendo las cosas bien y cuando mal. Funciona en cierta medida, como cuando uno quiere entrenar a un perro a realizar tal comportamiento. Generalmente, se lo refuerza con algo placentero, como darle comida luego de haber realizado una acción deseada. Otro ejemplo posible, es suponiendo que uno quiere entrenar a un robot a caminar. Podemos definirle que lo bueno es cuando logra caminar y lo malo, cuando se cae. De esta forma, por prueba y error, la tecnología de Machine Learning, va logrando ajustar sus algoritmos, para obtener el resultado que le vamos indicando como bueno.

Aprendizaje no supervisado

El aprendizaje no supervisado, también conocido como machine learning no supervisado, utiliza algoritmos de machine learning para analizar y agrupar conjuntos de datos no etiquetados, o sea datos que no están descritos. Estos algoritmos descubren patrones ocultos o agrupaciones de datos sin necesidad de intervención humana. Su capacidad de descubrir similitudes y diferencias en la información la convierte en la solución ideal para análisis exploratorio de datos, estrategias de venta cruzada, segmentación de clientes y reconocimiento de imágenes.

Underfitting o subajuste y overfitting o sobreajuste en Machine Learning

Los principales obstáculos al lograr buenos resultados en Machine Learning son el sobreajuste y el subajuste. Estos términos se refieren a la capacidad de un modelo para generalizar lo aprendido a nuevos datos. Cuando un modelo sufre de sobreajuste, se adapta demasiado a los datos de entrenamiento, incluyendo el ruido, lo que le impide realizar predicciones precisas sobre datos no vistos. Por otro lado, el subajuste ocurre cuando el modelo es demasiado simple y no captura las relaciones subyacentes en los datos, lo que también afecta su capacidad de generalización.

Subajuste

Ocurre cuando un modelo es demasiado simple para capturar las relaciones subyacentes en los datos. No puede generalizar bien a nuevos datos y, por lo tanto, su rendimiento es bajo tanto en el conjunto de entrenamiento como en el de prueba.

Si los datos de entrenamiento son muy pocos, la máquina no será capaz de generalizar el conocimiento. Por ejemplo, si mostramos solo una raza de gatos y pretendemos que pueda reconocer otras diez razas de felinos distintas, el algoritmo no será capaz de darnos un resultado adecuado por falta de “contenido” para hacer sólido su conocimiento.

Causas

- Modelo demasiado simple: La elección de un algoritmo con poca capacidad de aprendizaje.
- Pocos datos de entrenamiento: No hay suficiente información para que el modelo aprenda patrones complejos.
- Características irrelevantes: Se utilizan características que no están relacionadas con la variable objetivo.

Consecuencias

Alto error tanto en el conjunto de entrenamiento como en el de prueba.

Sobreajuste

Ocurre cuando un modelo se ajusta demasiado a los datos de entrenamiento, capturando incluso el ruido aleatorio. Esto lleva a un excelente rendimiento en el conjunto de entrenamiento pero a un pobre rendimiento en nuevos datos.


Causas

- Modelo demasiado complejo: El modelo tiene demasiados parámetros libres, lo que le permite memorizar los datos de entrenamiento en lugar de aprender patrones generales.
- Datos de entrenamiento insuficientes: El modelo se ajusta demasiado a las particularidades de los datos de entrenamiento, sin poder generalizar.

Consecuencias

Bajo error en el conjunto de entrenamiento y alto error en el conjunto de prueba. Esto quiere decir que si bien el modelo es capaz de hacer predicciones muy precisas sobre los datos que ya conoce, tiene dificultades para hacer predicciones correctas sobre datos nuevos que no ha visto durante el entrenamiento.

Se debe encontrar un punto medio en el aprendizaje del en el que se está incurriendo en subajuste y tampoco en sobreajuste. A veces esto puede resultar una tarea muy difícil.



SUBAJUSTE (UNDERFITTING)	SOBREAJUSTE (OVERFITTING)
<p>Si los datos de entrenamiento son muy pocos, la máquina no será capaz de generalizar el conocimiento. Por ejemplo, si mostramos solo una raza de gatos y pretendemos que pueda reconocer otras diez razas de felinos distintas, el algoritmo no será capaz de darnos un resultado adecuado por falta de “contenido” para hacer sólido su conocimiento.</p>	<p>Cuando entrenamos a la máquina mostrándole diez razas de gatos de color negro, si luego probamos con la foto de uno blanco, el modelo no podrá reconocerlo como tal por no cumplir exactamente con las características que aprendió.</p>

Más info en

<https://www.aprendemachinelearning.com/que-es-overfitting-y-underfitting-y-como-solucionarlo/>

Mitos de la IA |

"La IA genera resultados totalmente objetivos"

“Esta herramienta de inteligencia artificial predice resultados médicos mejor que la mayoría de doctores”, señala un titular en un medio digital. Sin embargo, poco se dice de los datos con los que los modelos se entrenan, o sobre el conjunto de datos invisibles (llamado conjunto de prueba o validación) que se utilizan para llegar a los resultados. También, en general, suele quedar invisibilizada la construcción de los algoritmos, es decir las instrucciones para tomar las decisiones.

Cuando nos referimos a datos no sólo hablamos de letras o números: también hablamos de imágenes, rostros humanos, datos biométricos de las personas, sonidos, huellas dactilares, estudios médicos, es decir, una gran cantidad de información disponible en bases de datos públicas y privadas. Considerarlo es relevante ya que, como señala Kate Crawford (2023) “los sistemas de aprendizaje automático se entrenan con imágenes como estas todos los días, imágenes obtenidas de internet o de instituciones estatales, sin contexto y sin consentimiento”. La autora agrega: “Son cualquier cosa menos neutrales. Representan historias personales, desigualdades estructurales (...) Pero la presunción de que, de alguna manera, estas imágenes pueden servir como materiales apolíticos inertes influye en el cómo y en el qué ve una herramienta de aprendizaje automático”.

El contexto de los datos, la construcción de la diversidad de la base de entrenamiento y la capacidad de representación que tienen, es extremadamente relevante para obtener resultados confiables en los sistemas de IA.

Hay muchos motivos para ser precavidos y no confiar tanto en los algoritmos como árbitros finales de las decisiones, ya que, en el mejor de los casos, solo proporcionan perspectivas útiles. Cualquier reclamo de justicia de los algoritmos debe calificarse por el hecho de que el proceso de toma de decisiones algorítmica tiene dos elementos clave:

i) programadores humanos que toman decisiones críticas para enmarcar el problema y la validez del resultado

ii) datos que pueden representar sesgos históricos, tergiversar grupos o no representarlos en absoluto. Las interfaces de computadora humana casi nunca se crean teniendo en cuenta a las personas transgénero, y continúan reforzando los prejuicios existentes. Los problemas pueden ser graves para las personas transgénero y no binarias porque la mayoría del software de reconocimiento facial está programado para clasificar a las personas en dos grupos: hombres o mujeres. Y así podemos pensar varios ejemplos de grupos que no están siendo representados.

Cuestionar los modelos de la IA

Parte de nuestra labor es cuestionar esas afirmaciones, profundizando a través de preguntas sobre los datos del modelo, la verificación de los mismos en el mundo real o solicitar ejemplos concretos de su implementación. Algunas preguntas que ayudarán a avanzar en la precisión son, por ejemplo:

- ¿Qué tipos de datos y de qué fuentes se utilizaron para su entrenamiento?
- ¿A partir de esta prueba concreta, podemos generalizar la conclusión a otros ámbitos, o tendríamos que realizar distintas pruebas con otros conjuntos de datos?
- ¿Se probó el modelo en teoría o en su ámbito concreto de dominio?
- ¿Dónde o en qué sesgos se detectan estos errores?
- ¿Cómo se trabajará para resolverlos?

En términos de derechos de las personas, es vital que los modelos de IA garanticen resultados equitativos. En este sentido, la pregunta sobre cómo funciona un modelo entre diferentes grupos de personas es la más importante en pos de evitar discriminación o sesgos (de género, raciales, socioeconómicos, culturales, etc). Por ejemplo, en el caso de herramientas de detección de enfermedades a través de imágenes, es sumamente relevante considerar los falsos positivos o el entrenamiento de los sistemas en personas de distintos grupos etarios o lugares geográficos, ya que la utilización de estas tecnologías sin supervisión humana puede dar lugar a tratamientos desde ineficaces hasta nocivos para la salud. Los sistemas de reconocimiento facial son particularmente propensos a devolver falsos positivos.